

OWNML MACHINE LEARNING CANVAS

PREDICTION TASK



Tipo de tarefa e definição do alvo.

- Tipo: classificação supervisionada binária
- Entidade: clientes de telecomunicações (base ativa)
- Saída: churn (1) vs. não churn (0) + score de probabilidade (0–1)

Horizonte: cancelamento observado no próximo ciclo mensal (~30 dias)

DECISIONS



Como o score se converte em ação.

- O modelo gera um score de churn por cliente.
 - Segmentação por risco (exemplo):
 - Alto (> 0,70): retenção ativa (call center + oferta)
 - Médio (0,50–0,70): campanhas automatizadas
 - Baixo (< 0,50): monitoramento

Threshold ajustado por custo x benefício, capacidade operacional e valor do cliente.

VALUE PROPOSITION



- Beneficiários:
Marketing/Retenção, CRM e Diretoria

- Problemas: churn sem previsibilidade, ações reativas e baixa eficiência de campanhas

- Valor gerado: redução de churn, preservação de receita e melhor alocação de recursos

Entrega/integração: API REST (/api/v1/predict), dashboard analítico e integração com CRM/ferramentas de campanha

DATA COLLECTION



- Dataset fornecido pela faculdade (base controlada)
- ~7.000 clientes
- Target (churn) com base em cancelamento no último mês
- Simulação de produção:

Pipeline ETL automatizado

Atualização batch periódica validação de dados com Pandera

DATA SOURCES



- Dataset único contendo: Dados demográficos

Serviços contratados

Informações financeiras

- Em produção (referência):
 - CRM
 - billing/faturamento

sistemas de provisionamento/serviços

IMPACT SIMULATION



- Custos/benefícios:
TP: retenção de cliente (preserva receita)
FP: custo de campanha/contato
FN: perda de cliente e receita

- Critérios de sucesso:
ROI positivo e redução do churn

- Riscos/limitações:
Desbalanceamento de classes (~27% churn)

Possível viés em contract_type e payment_method

Dataset acadêmico e ausência de dados comportamentais

MAKING PREDICTIONS



- Serviço de inferência via API REST

POST /api/v1/predict

- Latência (meta): P95 < 200 ms

- Frequência: Real-time

Integração direta com sistemas de negócio (CRM/campanhas)

BUILDING MODELS



- Modelos:

ChurnMLP (PyTorch) — modelo principal

Logistic Regression — baseline

DummyClassifier — referência

- Treinamento:

Split 70/15/15

Versionamento e tracking via MLflow pipeline automatizado (treino → validação → registro)

FEATURES



- Disponíveis:
demográficas, serviços e financeiras

- Principais usadas: tenure, monthly_charges, total_charges, contract_type, payment_method, has_phone_service, has_internet_service, has_online_security

- Excluídos: customerID (sem valor preditivo)

Engenharia: normalização, encoding categórico e validação de schema

MONITORING



- **Métricas técnicas:** AUC-ROC, F1-score, precisão/recall e calibração

- **Drift & qualidade de dados:** data drift, outliers e quebras de schema (Pandera)

- **Métricas operacionais:** latência (P95), taxa de erro, disponibilidade e volume de requests

- **Alertas & re-treino:** alertas por degradação (ex.: >5% no F1) e re-treino mensal ou sob gatilho

- **Métricas de negócio:** redução de churn, receita preservada e uplift por campanha

- **Ferramentas:** MLflow (tracking/registry) + logs da API + dashboard de observabilidade